

GPT-2 加速器分析

朱国伟

December 7, 2025

参数定义总表

- **控制参数 (模型本身):** B (Batch Size), H (Hidden Size), A (Heads), D_h (Head Dim), L (Seq Len), DW (Data Width).
- **架构参数 (硬件设计):** W_k/H_k (阵列尺寸), V_k (向量长度), BW_k (各级带宽).
- **IO 符号:** R_W (读权重), R_{In} (读输入/KV), W_{Out} (写输出).

算核参数分类总结:

以下内容为针对 decode 过程的加速。对于 prefill, 除了两个点积阵列外, 其他以 decode 方式计算不会影响效率。对于两个点积阵列, 也只需要修改数据加载的逻辑, 使其变成矩阵乘法阵列即可; 特殊函数架构参数是维度带宽和数据精度, 控制参数是处理数据的大小; 矩阵乘法架构参数是长宽、精度以及带宽, 控制参数是分块参数以及乘法的大小; 点积阵列的架构参数包括每个点积单元的维度和点积单元的数量以及精度和带宽, 控制参数同样是乘法的大小。





Figure 1: 三种算核结构

Table 1: GPT-2 Decode 流水线详细实现参数表

基本结构	相关参数 (架构/控制)	常见设置	计算周期	IO 周期 (读写分离)	数据重组 (Why & How)
S1: LayerNorm 向量单元	架构: V_1, BW_1, DW 控制: B, H	$H\%V_1 = 0$	$\frac{B \cdot H}{V_1}$	$R_{In}: \frac{BH \cdot DW}{BW_1}$ $W_{Out}: \frac{BH \cdot DW}{BW_1}$	不需要 数据维度无变化, 纯向量点对点操作。
S2: QKV Proj 矩阵乘法阵列	架构: W_2, H_2, BW_2, DW 架构: N_2 控制: 分块因子。 含义: 因加速器上存不下 $3H^2$ 权重, 需将权重切成 N_2 块。 每加载一块权重, 输入 BH 就必须重新加载一次。 控制: B, H	$H\%W_2 = 0$	$\frac{3 \cdot B \cdot H^2}{W_2 \cdot H_2}$	$R_W: \frac{3H^2 \cdot DW}{BW_2}$ $R_{In}: \frac{N_2 \cdot BH \cdot DW}{BW_2}$ (输入重复 N_2 次) $W_{Out}: \frac{3BH \cdot DW}{BW_2}$	需要 Why: S2 输出是混合的 $[B, 3H]$, 但 S3 需要按头独立读取 $[B, A, D_h]$ 。 How: 将每个头存放在一块存储中
S3: Score 点积阵列	架构: V_3, H_3, BW_3, DW 控制: B, A, L, D_h	$V_3 = D_h$	$\frac{BAL}{H_3}$	$R_K: \frac{BALD_h \cdot DW}{BW_3}$ (瓶颈: 读历史 Key) $W_S: \frac{BAL \cdot DW}{BW_3}$	不需要 S2 已完成 Bank 存储, 本级直接从对应 Bank 并行读取 Query 即可。
S4: Softmax SFU 流水线	架构: V_4, DW 控制: B, A, L	流水线设计	$\frac{BAL}{V_4}$	0 数据在片上流转	不需要
S5: Context 点积阵列	架构: V_5, H_5, BW_5, DW 控制: B, A, L, D_h	$V_5 = D_h$	$\frac{BAL}{H_5}$	$R_V: \frac{BALD_h \cdot DW}{BW_5}$ (瓶颈: 读历史 Value) $W_O: \frac{BH \cdot DW}{BW_5}$	需要 Why: 本级输出是分散的头 $[B, A, D_h]$, S6 需要拼接后的 $[B, H]$ 。 How: S5 的并行单元同时输出 A 个头的结果, 通过总线直接拼成一个宽向量写入下一级 Buffer。

续下页...

Table 1 – 接上页

结构	参数	设置	计算	IO	重组
S6: Out Proj 矩阵乘法阵列	架构: W_6, H_6, BW_6, DW 控制: N_6 (分块因子) 含义: 权重 H^2 若超 SRAM 容量, 需分 N_6 块, 输入重复加载 N_6 次。 控制: B, H	同 S2	$\frac{B \cdot H^2}{W_6 \cdot H_6}$	$R_W: \frac{H^2 \cdot DW}{BW_6}$ $R_{In}: \frac{N_6 \cdot BH \cdot DW}{BW_6}$ $W_{Out}: \frac{BH \cdot DW}{BW_6}$	不需要
S7-Res: Add 残差连接 1 加法向量单元	架构: V_7, BW_7, DW 控制: B, H	$H \% V_7 = 0$	$\frac{B \cdot H}{V_7}$	R_{S1} : 读取 S1 输入副本 R_{S6} : 读取 S6 输出 $W_{Out}: \frac{BH \cdot DW}{BW_7}$	不需要
S8: LayerNorm 向量单元	架构: V_8, BW_8, DW 控制: B, H	$H \% V_8 = 0$	$\frac{B \cdot H}{V_8}$	$R_{In}: \frac{BH \cdot DW}{BW_8}$ $W_{Out}: \frac{BH \cdot DW}{BW_8}$	不需要 数据维度无变化, 纯向量点对点操作。
S9: FFN Up 宽矩阵乘法阵列	架构: W_9, H_9, BW_9, DW 控制: N_9 (分块因子) 含义: 权重 $4H^2$ 极大, IO 压力剧增。 控制: B, H	H_9 较大	$\frac{4BH^2}{W_9 H_9}$	$R_W: \frac{4H^2 \cdot DW}{BW_9}$ $R_{In}: \frac{N_9 \cdot BH \cdot DW}{BW_9}$ $W_{Out}: \frac{4BH \cdot DW}{BW_9}$	不需要
S10-Act: GELU 激活函数 向量单元	架构: V_{10}, BW_{10}, DW 控制: B, H 注意: 数据量是 $4H$	$4H \% V_{10} = 0$	$\frac{4 \cdot B \cdot H}{V_{10}}$	$R_{In}: \frac{4BH \cdot DW}{BW_{10}}$ $W_{Out}: \frac{4BH \cdot DW}{BW_{10}}$	不需要

续下页...

Table 1 – 接上页

结构	参数	设置	计算	IO	重组
S11: FFN Down 矩阵乘法阵列	架构: W_11, H_11, BW_11, DW 控制: N_11 (分块因子) 含义: 需注意本级输入维度为 $4H$, 故数据重载量大。 控制: B, H	同 S2	$\frac{4BH^2}{W_11H_11}$	$R_W: \frac{4H^2 \cdot DW}{BW_11}$ $R_{In}: \frac{N_11 \cdot 4BH \cdot DW}{BW_11}$ $W_{Out}: \frac{BH \cdot DW}{BW_11}$	不需要
S12-Res: Add 残差连接 2 向量加法器	架构: V_{12}, BW_{12}, DW 控制: B, H	同 S6-Res	$\frac{B \cdot H}{V_{12}}$	R_{S7R} : 读 S7 输出 R_{S11} : 读 S11 输出 $W_{Out}: \frac{BH \cdot DW}{BW_{12}}$	不需要